LAB09_IsaDias

Isabella Ferreira Dias 266903

Laboratório 9: Dados Relacionais com Polars

Teste do Polars

```
import polars as pl

print("Polars funcionando!")
print("Versão:", pl.__version__)
```

```
Polars funcionando!
Versão: 2.0.0
```

Questão 1 — Os cinco filmes com maior avaliação média

Para responder à questão, selecionamos os títulos classificados como filmes (`titleType == "movie"`) e juntamos suas informações às avaliações. Ordenamos primeiro pela avaliação média, em ordem decrescente, e depois pelo número de votos, também em ordem decrescente, para desempatar.

```
import polars as pl

filmes = (
    pl.scan_csv(
        "title.basics0.tsv.gz",
        separator="\t",
        null_values="\\N"
    )
    .filter(pl.col("titleType") == "movie")
```

```
    .select(["tconst", "primaryTitle", "startYear"])
)

avaliacoes = pl.scan_csv(
    "title.ratings.tsv.gz",
    separator="\t",
    null_values="\\N"
)

resultado1 = (
    filmes
    .join(avaliacoes, on="tconst", how="inner")
    .sort(
        ["averageRating", "numVotes"],
        descending=[True, True]
    )
    .select([
        "primaryTitle",
        "startYear",
        "averageRating",
        "numVotes"
    ])
    .head(5)
    .collect()
)

resultado1
```

primaryTitle str	startYear i64	averageRating f64	numVotes i64
”Kaveri”	2024	10.0	1023
”Kurukku”	2024	10.0	451
”Jedal Dar Omghe 30 Metri”	2009	10.0	142
”Sargashte”	2016	10.0	134
”Gorgeous Rascal”	2024	10.0	115

Resultado e interpretação: os cinco filmes retornados apresentam avaliação média de 10,0. Como há empate na avaliação, o número de votos é utilizado como critério de desempate.

Questão 2 — Gênero mais frequente entre filmes com avaliação superior a 8

Primeiro, selecionamos os filmes com avaliação média superior a 8. Depois, separamos os gêneros de cada filme, pois um mesmo título pode pertencer a mais de um gênero. Por fim, contamos as ocorrências de cada gênero e ordenamos as frequências em ordem decrescente.

```
basicos = (
    pl.scan_csv(
        "title.basics0.tsv.gz",
        separator="\t",
        null_values="\\N"
    )
    .filter(pl.col("titleType") == "movie")
    .select(["tconst", "genres"])
)

avaliacoes_altas = (
    pl.scan_csv(
        "title.ratings.tsv.gz",
        separator="\t",
        null_values="\\N"
    )
    .filter(pl.col("averageRating") > 8)
    .select(["tconst", "averageRating"])
)

resultado2 = (
    basicos
    .join(avaliacoes_altas, on="tconst", how="inner")
    .filter(pl.col("genres").is_not_null())
    .with_columns(pl.col("genres").str.split(","))
    .explode("genres")
    .group_by("genres")
    .agg(pl.len().alias("frequencia"))
    .sort("frequencia", descending=True)
    .head(10)
    .collect()
)

resultado2
```

genres str	frequencia u32
”Documentary”	10564
”Drama”	8114
”Comedy”	3186
”Biography”	1395
”Romance”	1363
”Action”	1355
”Music”	1248
”Thriller”	1184
”History”	1030
”Crime”	977

Resultado e interpretação: o gênero mais frequente foi **Documentary**, com 10.564 ocorrências. A contagem considera cada gênero separadamente, inclusive quando um filme possui vários gêneros.

Questão 3 — Três atores ou atrizes com mais participações em filmes avaliados acima de 7,5

Selecionamos os filmes com avaliação média superior a 7,5 e juntamos suas identificações às informações do elenco. Mantivemos apenas as categorias `actor` e `actress`, agrupamos as participações por pessoa e contamos o número de filmes.

```
avaliacoes_questao3 = (
    pl.scan_csv(
        "title.ratings.tsv.gz",
        separator="\t",
        null_values="\\N"
    )
    .filter(pl.col("averageRating") > 7.5)
    .select("tconst")
)

filmes_questao3 = (
    pl.scan_csv(
        "title.basics0.tsv.gz",
        separator="\t",
        null_values="\\N"
```

```
    )
    .filter(pl.col("titleType") == "movie")
    .select("tconst")
)

elenco = (
    pl.scan_csv(
        "title.principals0.tsv.gz",
        separator="\t",
        null_values="\\N"
    )
    .filter(pl.col("category").is_in(["actor", "actress"]))
    .select(["tconst", "nconst"])
)

resultado3 = (
    filmes_questao3
    .join(avaliacoes_questao3, on="tconst", how="inner")
    .join(elenco, on="tconst", how="inner")
    .group_by("nconst")
    .agg(pl.len().alias("quantidade_filmes"))
    .sort("quantidade_filmes", descending=True)
    .head(3)
    .collect()
)

resultado3
```

nconst str	quantidade_filmes u32
”nm0004660”	231
”nm0595934”	155
”nm3183374”	124

Para identificar os nomes correspondentes aos identificadores retornados, consultamos o arquivo `name.basics.tsv.gz`, lendo-o linha por linha para evitar carregar toda a tabela na memória.

```
import gzip

ids = set(resultado3["nconst"].to_list())
```

```
nomes = {}

with gzip.open(
    "name.basics.tsv.gz",
    "rt",
    encoding="utf-8"
) as arquivo:
    next(arquivo)

    for linha in arquivo:
        partes = linha.rstrip("\n").split("\t")

        if partes[0] in ids:
            nomes[partes[0]] = partes[1]

            if len(nomes) == len(ids):
                break

tabela_nomes = pl.DataFrame({
    "nconst": list(nomes.keys()),
    "nome": list(nomes.values())
})

resultado_final3 = (
    resultado3
    .join(tabela_nomes, on="nconst", how="left")
    .select(["nome", "quantidade_filmes"])
)

resultado_final3
```

nome str	quantidade_filmes u32
”Rajkumar”	231
”Mohan Babu”	155
”T.N. Balakrishna”	124

Resultado e interpretação: os três nomes identificados foram Rajkumar, Mohan Babu e T.N. Balakrishna, com 231, 155 e 124 participações, respectivamente, conforme a contagem realizada.

HORÁRIO DE COMPILAÇÃO

```
Sys.setenv(TZ = "America/Sao_Paulo")
data_hora <- format(Sys.time(), "%d/%m/%Y às %H:%M:%S")
data_hora
```